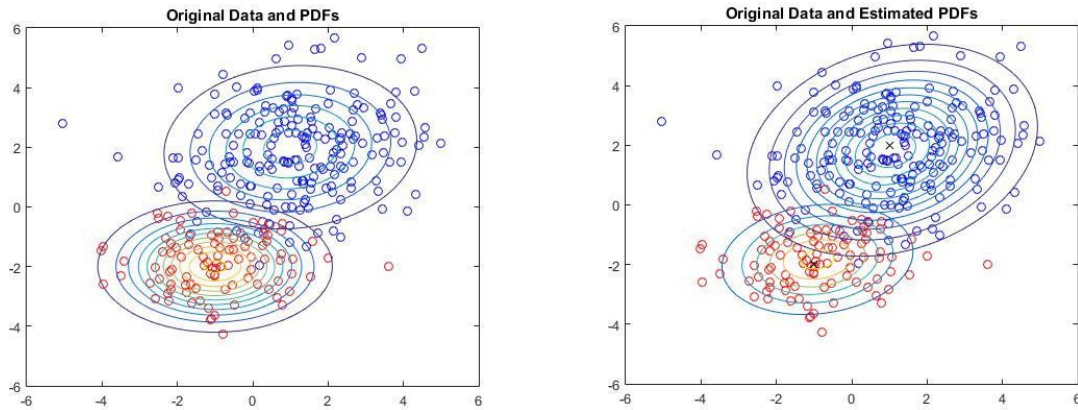


4105109 電腦視覺 (Computer Vision)

Project #3 – Gaussian Mixture Model

Deadline : 12/12 (Tue) 11:59 p.m.



Trace the matlab code of Gaussian Mixture Model. Write your report:

- Part 1: Trace the code to understand how EM algorithm works for GMM ([GMM_Examples_v2014_08_04: GMMExample_2D.m](#)). Get to know each parameter in this method and each variable in this code. Include the source code in your report. Write detailed program comments to explain **each line** (what it calculate? how it calculate?).
- Part 2: Write a report to explain Gaussian Mixture Model and how EM algorithm solves its parameters.

Note:

- Hand in the matlab code and the report to E-Course.
- 報告、程式註解請以中文撰寫，並繳交紙本報告一份
- Assignment format
 - Zip all your files into a single one and upload it to the E-Course website.
 - Please format the file name as:
Student ID_proj2_verNo ex:
602410143_proj2_v1

```

GMMExample_2D.m  x  +
1
2  %%=====
3  %% STEP 1a: Generate data from two 2D distributions.
4
5
6  mu1 = [1 2];           %第一個分布的mean vector
7  sigma1 = [ 3 .2;      %第一個分布的covariance vector
8             .2  2];
9  m1 = 200;             %第一個分布的data數量
10
11 mu2 = [-1 -2];         %第二個分布的mean vector
12 sigma2 = [2 0;        %第二個分布的covariance vector
13            0 1];
14 m2 = 100;             %第二個分布的data數量
15
16 R1 = chol(sigma1);     % Cholesky分解用於生成相應的data
17 X1 = randn(m1, 2) * R1; % 從標準正態分布生成data
18 X1 = X1 + repmat(mu1, size(X1, 1), 1); % 將生成的data平移至目標分布
19
20 R2 = chol(sigma2);
21 X2 = randn(m2, 2) * R2;
22 X2 = X2 + repmat(mu2, size(X2, 1), 1);
23
24 X = [X1; X2];         % 將兩個分布的data合併為X
25
GMMExample_2D.m  x  +
26  %%=====
27  %% STEP 1b: Plot the data points and their pdfs.
28
29  figure(1); % 繪製第一張圖
30
31  hold off;
32  plot(X1(:, 1), X1(:, 2), 'bo'); % 繪製第一個分布的data並將data標記為藍色圓點
33  hold on;
34  plot(X2(:, 1), X2(:, 2), 'ro'); % 繪製第二個分布的data並將data標記為紅色圓點
35
36  set(gcf, 'color', 'white')      % 設置圖形背景為白色
37
38  gridSize = 100;                 % 定義網格大小，即每個維度上的點數
39  u = linspace(-6, 6, gridSize); % 生成一個包含100個在-6到6之間等間隔的點的數組
40  [A B] = meshgrid(u, u);        % 使用meshgrid函數生成二維網格，A和B是矩陣，包含了u中對應x和y值的坐標
41  gridX = [A(:), B(:)];          % 將A和B矩陣的列堆疊，形成一個包含網格上所有點坐標的矩陣gridX
42
43  z1 = gaussianND(gridX, mu1, sigma1); % 利用gaussianND function計算第一個分布的概率密度
44  z2 = gaussianND(gridX, mu2, sigma2); % 利用gaussianND function計算第二個分布的概率密度
45
46  %將計算得到的概率密度z1, z2從一維數組轉換為二維矩陣Z1, Z2
47  %以便後續在圖形上進行等高線繪製
48  Z1 = reshape(z1, gridSize, gridSize);
49  Z2 = reshape(z2, gridSize, gridSize);
50
51  [C, h] = contour(u, u, Z1); % 繪製第一個分布的概率密度等高線
52  [C, h] = contour(u, u, Z2); % 繪製第二個分布的概率密度等高線
53

```

```
GMMExample_2D.m  +
54 axis([-6 6 -6 6]) % 設置坐標軸範圍
55 title('Original Data and PDFs');
56
57
58 %%=====
59 %% STEP 2: Choose initial values for the parameters.
60
61 m = size(X, 1);
62
63 k = 2; % GMM中的分量數
64 n = 2; % data的維度
65
66 indices = randperm(m);
67 mu = X(indices(1:k), :); % 從data中隨機選擇初始mean value
68
69 sigma = [];
70
71 for (j = 1 : k)
72     sigma{j} = cov(X); % 初始covariance matrix為data的協方差
73 end
74
75 phi = ones(1, k) * (1 / k); % 初始權重相等
76
77 %%=====
78 %% STEP 3: Run Expectation Maximization
79
80 W = zeros(m, k); % 設置權重矩陣
81
GMMExample_2D.m  +
82 for (iter = 1:1000)
83
84     fprintf(' EM Iteration %d\n', iter);
85
86     %%=====
87     %% STEP 3a: Expectation
88     pdf = zeros(m, k);
89
90     for (j = 1 : k)
91         pdf(:, j) = gaussianND(X, mu(j, :), sigma{j}); % 計算每個data對每個分量的概率密度
92     end
93
94     pdf_w = bsxfun(@times, pdf, phi); % 乘以權重
95
96     W = bsxfun(@divide, pdf_w, sum(pdf_w, 2)); % 歸一化權重矩陣
97
98     %%=====
99
100     %% STEP 3b: Maximization
101     %%
102     %% Calculate the probability for each data point for each distribution.
103
104     prevMu = mu;
105
106     for (j = 1 : k)
107
108         phi(j) = mean(W(:, j), 1); % 更新權重，使用每個分布的樣本權重的平均值
```

```
GMMExample_2D.m  ✕  +
110
111     mu(j, :) = weightedAverage(W(:, j), X); % 使用加權平均更新每個分布的mean value
112
113     sigma_k = zeros(n, n);
114
115     Xm = bsxfun(@minus, X, mu(j, :));
116
117     for (i = 1 : m)
118         sigma_k = sigma_k + (W(i, j) .* (Xm(i, :)' * Xm(i, :))); % 使用加權更新每個分布
119     end
120
121     sigma{j} = sigma_k ./ sum(W(:, j)); % 歸一化得到每個分布的新協方差矩陣
122 end
123
124 if (mu == prevMu) % 如果均值不再變化，結束EM算法的迭代
125     break
126 end
127
128 end
129
130 %=====
131 % STEP 4: Plot the data points and their estimated pdfs.
132
133 figure(2); % 繪製第二張圖
134 hold off;
135 plot(X1(:, 1), X1(:, 2), 'bo');
136 hold on;
137 plot(X2(:, 1), X2(:, 2), 'ro');
138
139 set(gcf, 'color', 'white')
140
141 plot(mu1(1), mu1(2), 'kx'); % 在data散點圖上標記第一個高斯分布的mean value位置
142 plot(mu2(1), mu2(2), 'kx'); % 在data散點圖上標記第二個高斯分布的mean value位置
143
144 gridSize = 100;
145 u = linspace(-6, 6, gridSize);
146 [A B] = meshgrid(u, u);
147 gridX = [A(:), B(:)];
148
149 % 利用更新完的mean與covariance計算兩個分布的概率密度
150 z1 = gaussianND(gridX, mu(1, :), sigma{1});
151 z2 = gaussianND(gridX, mu(2, :), sigma{2});
152
153 Z1 = reshape(z1, gridSize, gridSize);
154 Z2 = reshape(z2, gridSize, gridSize);
155
156 [C, h] = contour(u, u, Z1); % 繪製更新後第一個分布的概率密度等高線
157 [C, h] = contour(u, u, Z2); % 繪製更新後第二個分布的概率密度等高線
158 axis([-6 6 -6 6])
159
160 title('Original Data and Estimated PDFs');
```

Part1:

在 GMMExample_2D.m 的 MATLAB code 實現了一個混合高斯模型(GMM)的期望最大化算法(EM)。

以下是每個部分的詳細解釋：

(Step 1a)生成數據：

mu1 跟 sigma1 定義了第一個二維高斯分佈的均值跟協方差矩陣

mu2 跟 sigma2 定義了第二個二維高斯分佈的均值跟協方差矩陣

m1 跟 m2 分別指定了每個分佈的數據點數量

在設定完所有數值後就通過 Cholesky 分解來生成符合相對應的高斯分佈的隨機數據，然後進行平移以匹配目標分佈。並且最後再將生成的數據合併成 X。

(Step 1b)繪製第一張數據跟機率分佈：

使用藍色與紅色來分別繪製剛剛生成的高斯分佈的數據點，並且使用 gaussianND function 來計算網格上的 probability density，然後使用等高線繪製。

(Step 2)初始化參數：

隨機選擇初始的高斯分佈均值，並且選擇初始協方差矩陣作為協方差 [Cov(X)]，初始化權重 phi 被設定為相等。

(Step 3)執行 EM 算法：

(Step 3a)Expectation Step：

計算每個數據點屬於每個分佈的機率，並將其歸一化得到權重矩陣 W。

(Step 3b)執行 EM 算法：

使用權重迭代更新 GMM 的參數，包含每個分佈的均值 mu、協方差矩陣 sigma 和權重 phi。並且當更新後的均值不再變化就會停止。

(Step 4)繪製第二張估計的機率分佈：

在第二張圖上使用藍色和紅色分別繪製原始數據點，然後使用黑色交叉標記更新後的每個分佈的均值位置。接著利用更新後的均值和協方差計算估計的機率密度，並使用等高線繪製。

Part 2:

GMM：高斯混合模型是一種機率模型，通常用於描述包含多個高斯分佈的複雜數據分佈。GMM 的主要思想是，數據集中的每個觀察值都是由多個高斯分佈中的一個生成的，而每個高斯分佈對應一個特定的群體或模型組件。期望最大化算法是一種常用的方法，用於通過迭代優化模型參數，從而使模型更好地擬合數據。而 GMM 的數學表示如下：

$$p(x) = \sum_{k=1}^k \alpha_k N(x|\mu_k, \Sigma_k)$$

其中 α_k 是 mixture component 的權重， $N(x|\mu_k, \Sigma_k)$ 是高斯分佈的機率分佈函數， μ_k 和 Σ_k 分別是第 k 個高斯分佈的均值和協方差矩陣。

EM 算法：EM 算法是一種迭代優化算法，用於估計包含隱藏變量的機率模型參數。GMM 中的隱藏變量是每個數據點屬於每個高斯分布的機率。EM 算法包括兩個主要步驟：期望步驟(E step)和最大化步驟(M step)。

期望步驟(E step)：計算每個數據點屬於每個高斯分布的機率，得到權重矩陣 W 。這一步是通過計算高斯分布的機率密度來實現的。

$$P(b|x, \mu_b, V_b) = \frac{\alpha_b P(x|\mu_b, V_b)}{\sum_{i=1}^K \alpha_i P(x|\mu_i, V_i)}$$

最大化步驟(M step)：使用權重矩陣 W 來更新模型參數，包括每個高斯分布的均值、協方差矩陣和 mixture component 的權重。會不斷的迭代更新這些步驟直到收斂，即模型參數不再發生顯著變化。

$$\begin{aligned}\mu_b^{new} &= \frac{\sum_{i=1}^N x_i P(b|x_i, \mu_b, V_b)}{\sum_{i=1}^N P(b|x_i, \mu_b, V_b)} \\ V_b^{new} &= \frac{\sum_{i=1}^N (x_i - \mu_b^{new})(x_i - \mu_b^{new})^T P(b|x_i, \mu_b, V_b)}{\sum_{i=1}^N P(b|x_i, \mu_b, V_b)} \\ \alpha_b^{new} &= \frac{1}{N} \sum_{i=1}^N P(b|x_i, \mu_b, V_b)\end{aligned}$$

結論：高斯混合模型通過 EM 算法提供了一種強大的建模方法，能夠適應複雜的數據分布。EM 算法的期望步驟和最大化步驟通過迭代優化模型參數，使得模型更好地擬合數據。這種靈活性使得 GMM 成為許多模式識別和聚類任務中的首選方法之一。